Université / École : ecole polytechnique sousse

Filière : Génie Informatique – Business Intelligence

Module : Data Analytics & Business Intelligence

Titre du projet :

Analyse décisionnelle des Coupes du Monde FIFA

Réalisé par :

yassine ben hawala ,med aziz gannouni

Année universitaire :

2025/ 2026

INTRODUCTION.....2
CONTEXTE MÉTIER.....3
SOURCES DE DONNÉES.....3
ARCHITECTURE GLOBALE DE LA SOLUTION BI.....4
PROCESSUS ETL : EXTRACTION RÉSULTATS.....4
PROCESSUS ETL : TRANSFORMATION.....5
PROCESSUS ETL : CHARGEMENT.....6
MODÉLISATION DÉCISIONNELLE (DATA WAREHOUSE).....6
SCHÉMA EN ÉTOILE.....7
DATA VISUALISATION & KPIs (POWER BI).....8
DASHBOARD POWER BI.....8
INTÉGRATION DANS UNE APPLICATION MERN.....9
CONCLUSION ET PERSPECTIVES.....10

INTRODUCTION

Dans un contexte où les organisations s'appuient de plus en plus sur les données pour orienter leurs décisions, la Business Intelligence (BI) joue un rôle essentiel dans la transformation des données brutes en informations stratégiques. Les outils et méthodes de BI permettent d'analyser de grands volumes de données, de détecter des tendances et de faciliter la prise de décision.

Ce mini-projet s'inscrit dans le cadre du module *Data Analytics & Business Intelligence* et vise à mettre en œuvre un processus décisionnel complet à partir de données réelles. Le domaine sportif, et plus particulièrement les Coupes du Monde de la FIFA, constitue un terrain d'étude pertinent en raison de la richesse des données générées lors de chaque édition.

L'objectif principal de ce projet est de concevoir une solution BI complète intégrant un processus ETL, un entrepôt de données, des tableaux de bord analytiques et leur intégration dans une application MERN. Cette approche permet de couvrir l'ensemble de la chaîne décisionnelle, depuis la collecte des données jusqu'à leur exploitation par l'utilisateur final.

CONTEXTE MÉTIER

La Coupe du Monde de la FIFA est l'un des événements sportifs les plus médiatisés au monde. Chaque édition rassemble des équipes issues de différents pays et attire des millions de spectateurs, aussi bien dans les stades que via les médias. Cet événement génère ainsi un volume important de données liées aux performances sportives, aux phases de compétition, aux stades et à l'affluence.

L'analyse de ces données permet de répondre à plusieurs questions métier telles que :

- Quelle est l'évolution du nombre de buts au fil des éditions ?
- Les pays organisateurs influencent-ils l'attractivité et l'affluence ?
- Quelles phases de compétition sont les plus spectaculaires ?
- Quel stade a accueilli le plus grand nombre de buts ?
- Quelle phase (Finale, Demi-finale, Quart de finale, etc.) génère le plus de buts ?
- Quelle année compte le plus de buts ?

La Business Intelligence apporte une réponse structurée à ces problématiques en fournissant des indicateurs de performance clairs et des visualisations interactives permettant une analyse approfondie

SOURCES DE DONNÉES

Les données utilisées dans ce projet proviennent de la plateforme **Kaggle**, reconnue pour la mise à disposition de jeux de données ouverts et fiables. Deux fichiers principaux ont été exploités :

- **WorldCupMatches.csv** : ce fichier contient les informations détaillées sur les matchs des Coupes du Monde, telles que les équipes participantes, le nombre de buts, les stades, les phases de compétition et l'affluence par match.

- **WorldCups.csv** : ce fichier fournit des informations globales sur chaque édition, notamment l'année, le pays organisateur et l'affluence totale de la Coupe du Monde.

Ces données sont structurées sous forme de fichiers CSV et représentent des données réelles, cohérentes et adaptées à une analyse décisionnelle.

lien du dataset: https://www.kaggle.com/datasets/abecklas/fifa-world-cup

ARCHITECTURE GLOBALE DE LA SOLUTION BI

L'architecture globale de la solution repose sur un pipeline BI complet. Les données sources sont tout d'abord extraites à partir des fichiers CSV. Un processus ETL a ensuite été mis en place à l'aide de Python sur Google Colab afin de nettoyer, transformer et enrichir les données.

Les données transformées sont chargées dans un entrepôt de données relationnel basé sur SQLite, structuré selon un modèle en étoile. Cet entrepôt constitue la source principale d'analyse pour l'outil de data visualisation Power BI.

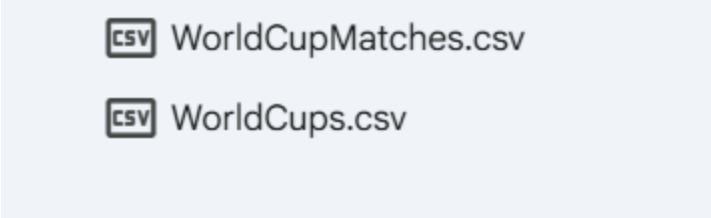
Enfin, les résultats analytiques sont intégrés dans une application MERN indépendante, permettant aux utilisateurs d'accéder aux tableaux de bord décisionnels via une interface web moderne.

PROCESSUS ETL : EXTRACTION RÉSULTATS

La phase d'extraction consiste à récupérer les données à partir des fichiers CSV fournis par Kaggle. Cette étape a été réalisée dans l'environnement Google Colab à l'aide du langage Python et de la bibliothèque Pandas.

Les fichiers *WorldCupMatches.csv* et *WorldCups.csv* ont été chargés en mémoire sous forme de DataFrames, ce qui a permis une manipulation efficace des données. Cette étape constitue la base du processus ETL et garantit l'accès aux données brutes avant

toute transformation.




```
matches_df = pd.read_csv("WorldCupMatches.csv")
cups_df = pd.read_csv("WorldCups.csv")
```

PROCESSUS ETL : TRANSFORMATION

La phase de transformation est une étape clé du processus ETL. Plusieurs opérations ont été appliquées afin d'améliorer la qualité et la cohérence des données.

Tout d'abord, un nettoyage des données a été effectué afin de supprimer les valeurs manquantes non pertinentes, notamment au niveau des buts marqués. Ensuite, les noms des colonnes ont été standardisés afin de faciliter la modélisation décisionnelle.

Une jointure a été réalisée entre les données des matchs et celles des Coupes du Monde sur la colonne *Year*. Cette jointure a permis d'enrichir les données des matchs avec le pays organisateur et l'affluence globale par édition. De plus, des mesures calculées ont été créées, telles que le nombre total de buts par match.

Ces transformations ont permis de préparer les données pour leur intégration dans l'entrepôt de données.

```
df = matches_df.merge(
    cups_df,
    on="Year",
    how="left"
)
```

```
df = df.dropna(subset=["HomeGoals", "AwayGoals"])
df["HomeGoals"] = df["HomeGoals"].astype(int)
df["AwayGoals"] = df["AwayGoals"].astype(int)

df["TotalGoals"] = df["HomeGoals"] + df["AwayGoals"]
```

PROCESSUS ETL : CHARGEMENT

Une fois les données transformées, la phase de chargement a consisté à insérer les données dans un entrepôt de données relationnel basé sur SQLite. Les données ont été organisées sous forme de tables de faits et de dimensions conformément au modèle décisionnel choisi.

Cette étape garantit la persistance des données et leur disponibilité pour les analyses ultérieures dans Power BI.

```
fact_match = df[
    [
        "MatchID",
        "Year",
        "HomeTeamID",
        "AwayTeamID",
        "HomeTeam",
        "AwayTeam",
        "HomeGoals",
        "AwayGoals",
        "TotalGoals",
        "Stage",
        "Stadium"
    ]
]

fact_match.to_sql("Fact_Match", conn, if_exists="append", index=False)
```

MODÉLISATION DÉCISIONNELLE (DATA WAREHOUSE)

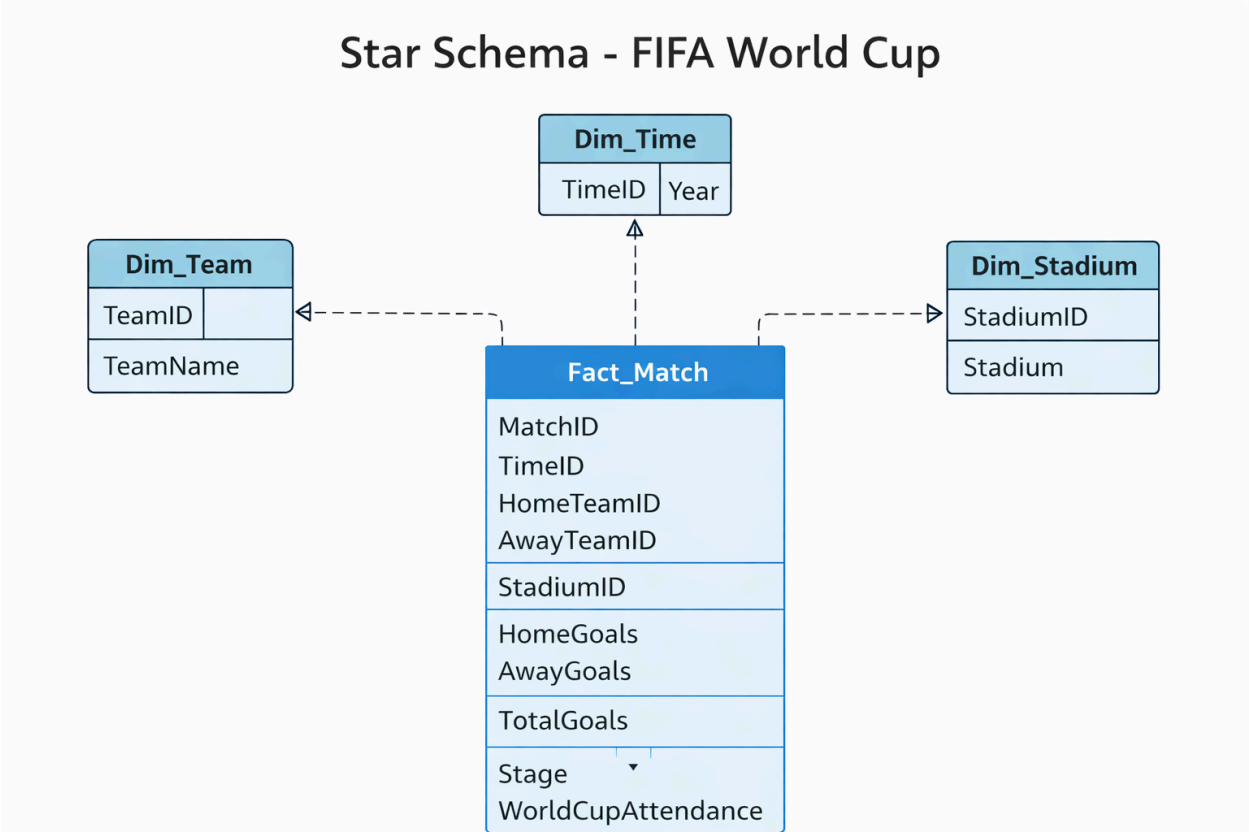
Afin de faciliter l'analyse décisionnelle, un modèle en étoile a été retenu. Ce modèle est composé d'une table de faits centrale et de plusieurs tables de dimensions.

Le modèle en étoile permet de simplifier les requêtes analytiques, d'améliorer les performances et de rendre la structure des données plus compréhensible pour les outils de visualisation.

SCHÉMA EN ÉTOILE

La table de faits **Fact_Match** regroupe les mesures quantitatives telles que le nombre de buts et l'affluence, ainsi que les clés étrangères vers les dimensions. Les tables de dimensions incluent :

- **Dim_Time** : analyse par année
- **Dim_Team** : analyse par équipes
- **Dim_Stadium** : analyse par stades

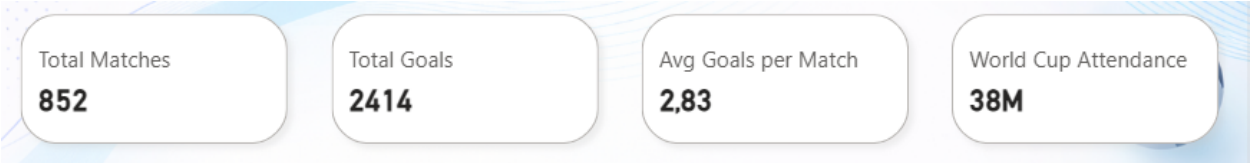


DATA VISUALISATION & KPIs (POWER BI)

L'analyse décisionnelle a été réalisée à l'aide de Power BI. Plusieurs indicateurs de performance clés (KPIs) ont été définis, notamment le nombre total de matchs, le nombre total de buts, la moyenne de buts par match et l'affluence moyenne.

Ces indicateurs permettent d'obtenir une vue globale des performances sportives et de l'attractivité des Coupes du Monde.

```
1  Total Goals =
2  SUM('Fact_Match (1)'[TotalGoals])
3
```



DASHBOARD POWER BI

Un tableau de bord interactif a été conçu afin de présenter les résultats de l'analyse. Le dashboard inclut des graphiques dynamiques et des filtres permettant à l'utilisateur d'explorer les données par année, phase de compétition et stade.

Cette approche favorise une analyse intuitive et une meilleure compréhension des tendances.

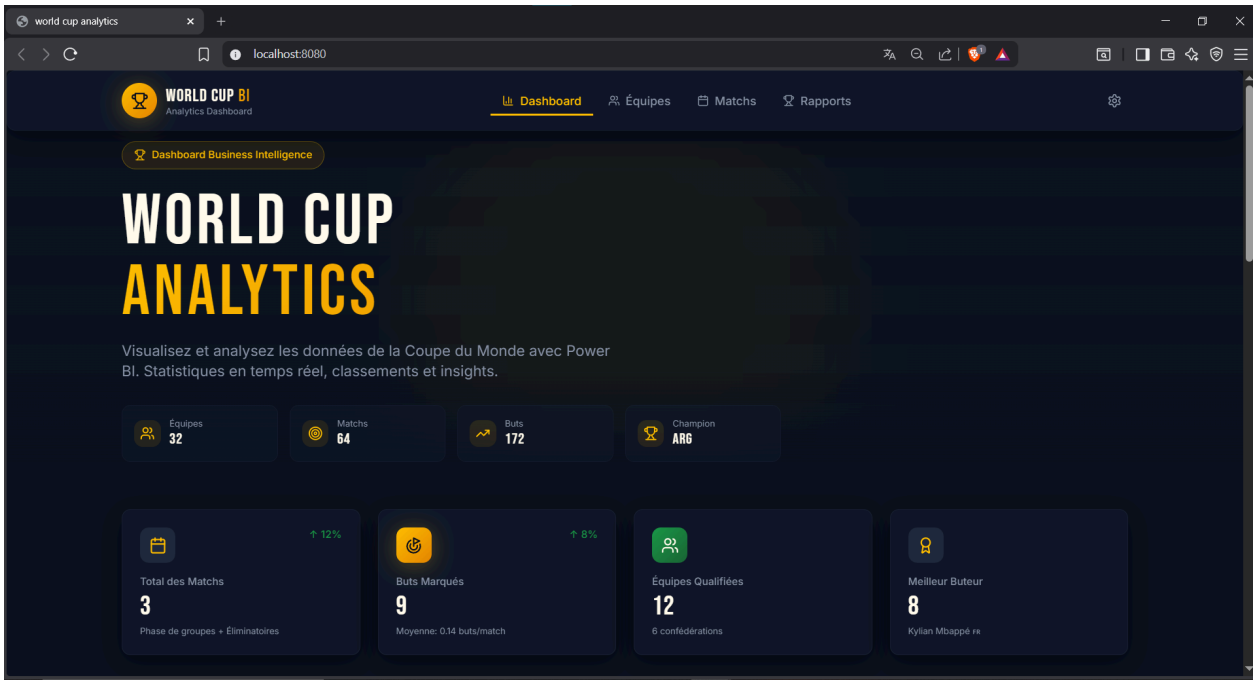


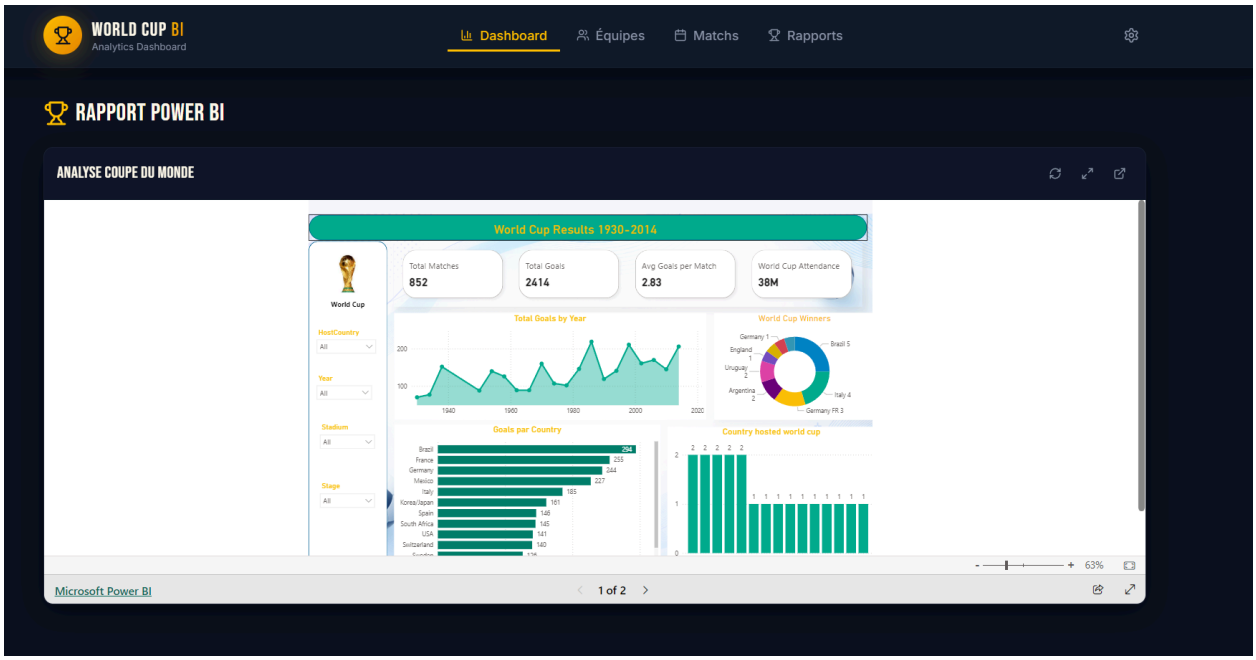


INTÉGRATION DANS UNE APPLICATION REACT

Une application web a été développée afin d'intégrer le tableau de bord Power BI dans une interface moderne. Le frontend a été réalisé avec React, TypeScript et Tailwind CSS.

L'intégration du dashboard a été effectuée via un iframe Power BI, permettant un accès direct aux analyses décisionnelles depuis l'application web. Les données sont gérées via une base de données connectée, avec des hooks React Query pour la récupération et la mise en cache des informations.





CONCLUSION ET PERSPECTIVES

Ce mini-projet a permis de mettre en œuvre un processus complet de Business Intelligence, depuis l'extraction des données jusqu'à leur exploitation décisionnelle. Les objectifs pédagogiques ont été atteints à travers la conception d'un entrepôt de données, la création de KPIs et le développement d'une interface MERN.

Comme perspectives, cette solution pourrait être enrichie par l'intégration de données supplémentaires sur les joueurs ou par la mise en place d'analyses prédictives afin d'anticiper certaines tendances futures.